MÓDULO 2 — DEEP LEARNING

Bloque 3

El Perceptrón y Cómo Aprenden las Máquinas

La unidad más pequeña de inteligencia artificial — desde cero.

Historia | Funcionamiento | Entrenamiento | Ejercicio práctico

El perceptrón — una idea de 1958

1943 — McCulloch & Pitts proponen el primer modelo matemático de neurona artificial

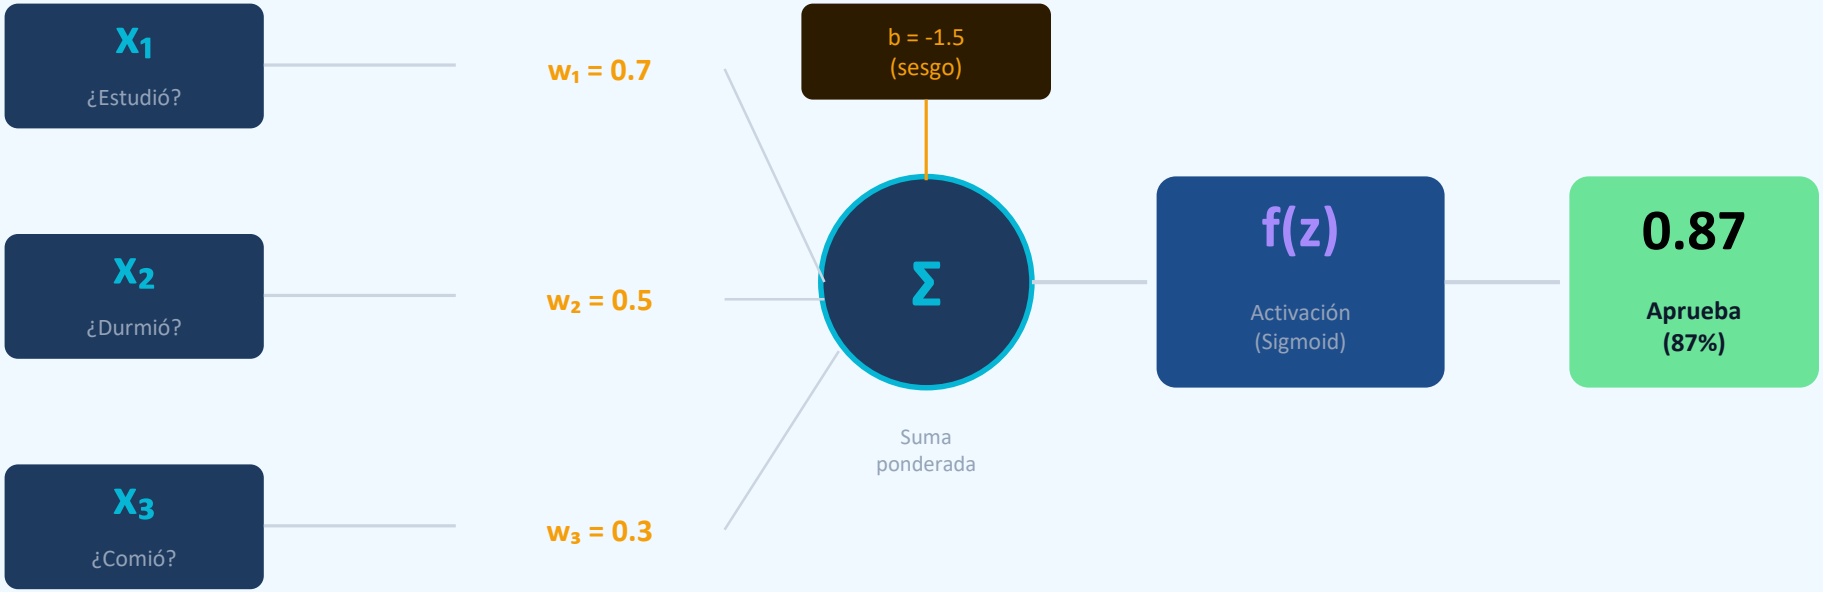
1958 — Frank Rosenblatt crea el Perceptrón — la primera red neuronal que 'aprende'

1969 — Minsky & Papert demuestran sus limitaciones. El 'invierno de la IA' comienza.

1986 — Rumelhart reinventa el Backpropagation. El perceptrón multicapa renace.

2012 — AlexNet gana ImageNet con Deep Learning. Empieza la era moderna de la IA.

El perceptrón por dentro — paso a paso



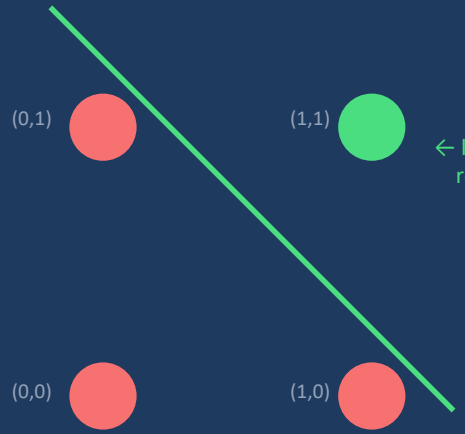
$z = w_1 \cdot x_1 + w_2 \cdot x_2 + w_3 \cdot x_3 + b$ → salida = sigmoid(z) → si ≥ 0.5: APRUEBA

El gran problema del perceptrón simple — el caso XOR

Un perceptrón solo puede separar datos con UNA línea recta. ¿Qué pasa cuando eso no alcanza?

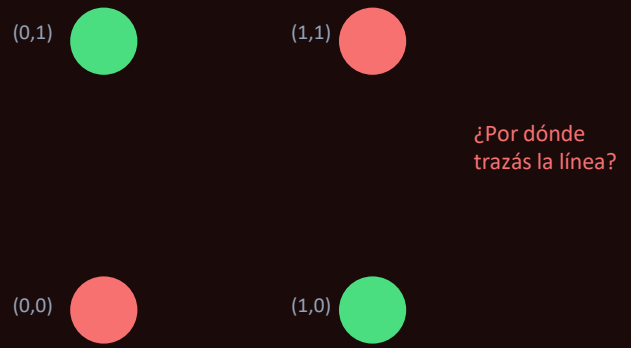
Problema AND — ☑ solucionable

Línea recta separa los puntos



Problema XOR — ✗ NO solucionable

No existe ninguna línea recta que separe estos puntos



La solución: apilar dos perceptrones → Red Neuronal Multicapa. Más capas = problemas más complejos.

¿Cómo 'aprende' un perceptrón? — Error, ajuste, iteración

🎯 Analogía: aprender a lanzar dardos a una diana sin poder verla, solo te dicen 'te fuiste para la izquierda' o 'te pasaste hacia arriba'.

1



Predecir

El perceptrón recibe un dato y calcula una salida con sus pesos actuales (aunque sean pésimos al principio).

2



Medir el error

Comparamos la predicción con la respuesta correcta. El 'error' es la diferencia entre lo que predijo y lo real.

3



Ajustar pesos

Los pesos se mueven un poquito en la dirección que reduce el error. Este ajuste se llama la 'regla del perceptrón'.

4



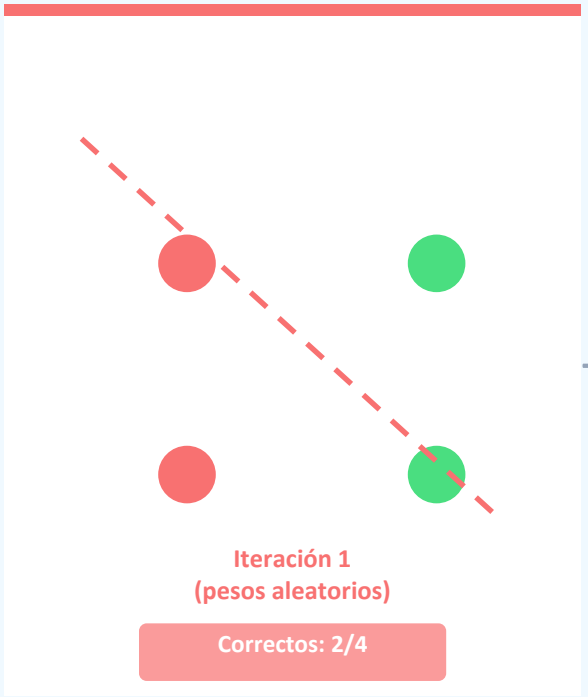
Repetir

Se repite miles de veces con distintos ejemplos. Cada vuelta el perceptrón se equivoca menos.

↑ se repite hasta que el error sea suficientemente pequeño

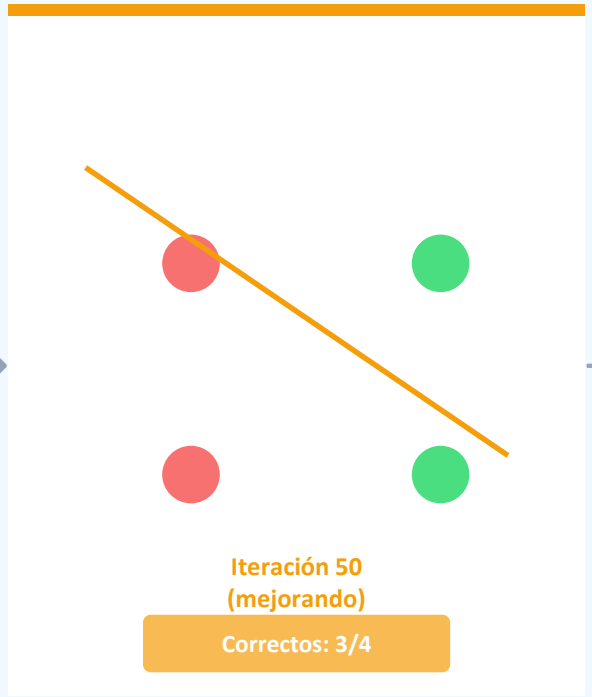
Visualizando el aprendizaje — la línea que se mueve

Cada iteración, la línea de separación se ajusta hasta clasificar correctamente todos los puntos:



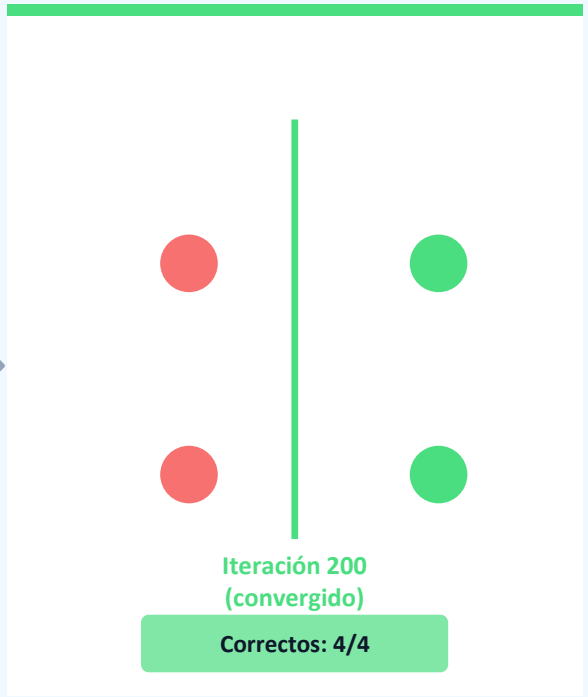
Iteración 1
(pesos aleatorios)

Correctos: 2/4



Iteración 50
(mejorando)

Correctos: 3/4



Iteración 200
(convergido)

Correctos: 4/4

Esto es exactamente lo que verás en el notebook — la línea moviéndose en tiempo real.

Los 3 tipos de aprendizaje que vas a escuchar



Supervisado

Analogía:

El maestro te da los ejercicios CON las respuestas correctas. Aprendés mirando ejemplos resueltos.

Ejemplo:

Clasificar emails como spam / no spam (ya tenemos miles etiquetados).

Lo más común. Lo que usamos con el perceptrón.



No supervisado

Analogía:

Te dan un montón de objetos mezclados y tenés que agruparlos solo, sin saber cuántos grupos hay.

Ejemplo:

Segmentar clientes de un banco en grupos similares sin saber de antemano cuántos grupos hay.

Clustering, reducción de dimensionalidad, detección de anomalías.



Refuerzo

Analogía:

Aprendés jugando. Cada acción recibe una recompensa o penalización. Te optimizás para ganar.

Ejemplo:

AlphaGo aprendió a jugar Go ganando millones de partidas contra sí mismo.

Robótica, videojuegos, optimización de procesos.

Ejercicio práctico — Notebook: Perceptrón paso a paso

Abrí Google Colab y seguí el notebook que compartimos. Vas a construir un clasificador desde cero en 4 partes:

Parte 1 ~10 min

El perceptrón manual

Implementar la neurona con Python puro. Sin librerías. Calculás z, aplicás sigmoid, ves la predicción.

Parte 2 ~10 min

El loop de entrenamiento

Escribís el ciclo que ajusta los pesos 100 veces. Vas a ver cómo el error va bajando en cada iteración.

Parte 3 ~10 min

El gráfico de la línea

Visualizás la línea de decisión moviéndose con matplotlib. Lo mismo que vimos en la presentación.

Parte 4 ~5 min

Tu propio dataset

Cambiás los datos de entrada y observás cómo el perceptrón aprende con tus propios ejemplos.

Resumen de hoy



El perceptrón es la unidad mínima de aprendizaje: toma entradas, las pondera y devuelve una salida.



Aprende ajustando sus pesos iterativamente usando el error como brújula: w_nuevo = w_viejo + η × error × x



Un solo perceptrón solo puede resolver problemas linealmente separables (como AND). Para XOR, necesitás más capas.



Existen 3 tipos de aprendizaje: Supervisado (con respuestas), No supervisado (agrupar) y Refuerzo (recompensa).

Próxima clase: Funciones de pérdida y evaluación de modelos →